

Аналитический отчёт с изложением результатов проделанной работы.

1. В ходе анализа и предварительной обработки данных выполнено:

- Загрузка датасета, вывод формы, информации о типах данных и сами данные. Признаки выводятся блоками по 10 для лучшей читаемости.
- Анализ пропущенных значений. Подсчитываются пропуски по столбцам. Выводится количество и доля пропущенных значений. Отмечаются строки с пропусками.
- Удалены все строки, содержащие пропуски.
- Группировка признаков по смыслу. Создаются списки с названиями признаков, объединёнными по категориям: `molwt_group`, `electrons_group`, `bcut2d_group`, `chi_group`, `kappa_group`, `*_vsa_group`, `fragments_group`, `state_index`, `partial_charge`, `mol_descriptors_group` и другие. Эта группировка может использоваться далее для анализа взаимосвязей внутри группы, для отбора признаков по тематике, для визуализации по категориям.
- Выведены статистики признаков по каждой группе.
- Сделана визуализация распределений и выбросов для каждой группы признаков.
- Найдены и удалены все нулевые и технические признаки.
- Выявлены закономерности и сделаны преобразования некоторых признаков.
- Сделана визуализация выбросов и распределений целевых переменных.
- Удалены выбросы
- Проанализирован биологический смысл целевых переменных
- Определено количество соединений в датасете, которые могут быть лекарствами.
- Сделан анализ датасета на наличие корреляций
- Удалены признаки с высокой корреляцией

2. В ходе создания модели для регрессии IC50 выполнено:

- Загрузка и подготовка данных
- Разделение данных на целевую переменную и признаки

- Выборки разделены на тестовую и тренировочную
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Проведена стандартизация признаков и применен PCA
- Обучены модели с применением базовых настроек и PCA
- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

Metrics

	MAE	RMSE	R2
Best RandomForest	107.846928	160.963393	0.128087
Best XGBoost	106.658306	161.657343	0.120553
Best CatBoost	111.840623	161.209746	0.125416

Выводы:

- RandomForest показывает лучшие метрики после настройки гиперпараметров.
- Ошибка предсказания (MAE) почти равна среднему значению самой переменной.
- Модель делает грубые предсказания, близкие по точности к простой константе.
- Польза модели ограничена – она пока не захватывает сложные закономерности в данных.
- R2 подтверждает это: модель объясняет очень небольшую часть дисперсии IC50

Рекомендации:

- Сделать ансамбль из лучших моделей: RandomForest, XGBoost.
- Применить PCA дифференцированно по группам признаков, чтобы учесть специфику различных блоков данных и избежать потерь важной информации при общей компрессии.
- Обратить внимание на биологическую значимость признаков

3. В ходе сознания модели для регрессии CC50 выполнено:

- Загрузка и подготовка данных
- Разделение данных на целевую переменную и признаки
- Выборки разделены на тестовую и тренировочную
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Проведена стандартизация признаков и применен PCA
- Обучены модели с применением базовых настроек и PCA

- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

Metrics

	MAE	RMSE	R2
Best RandomForest	228.359160	307.113727	0.277741
Best XGBoost	224.327068	303.588773	0.294226
Best CatBoost	235.052480	303.913759	0.292714

Выводы:

- Все модели имеют MAE в пределах 224–235, что означает среднюю ошибку примерно 60% от среднего значения CC50.
- RMSE около 303–307 это ниже стандартного отклонения 367.3, что говорит о том, что модели предсказывают лучше, чем просто среднее значение.
- R2 около 0.29 свидетельствует о наличии зависимости между признаками и целевой переменной.
- XGBoost с настройкой показал наилучшее качество (MAE, RMSE, R2).

Рекомендации:

- Использовать все три модели для предсказания CC50, как основные модели — они дают наилучший баланс между точностью и устойчивостью.
- Сделать ансамбль из CatBoost, RandomForest, XGBoost.

4. В ходе сознания модели для регрессии SI выполнено:

- Загрузка и подготовка данных
- Разделение данных на целевую переменную и признаки
- Выборки разделены на тестовую и тренировочную
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Проведена стандартизация признаков и применен PCA
- Обучены модели с применением базовых настроек и PCA
- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

Metrics	MAE	RMSE	R2
Best RandomForest	6.366227	8.617044	0.142637
Best XGBoost	6.312919	8.776830	0.110546
Best CatBoost	6.468937	8.659285	0.134211

Выводы:

- MAE 6.3 – 6.5 почти сравнимо с средним значением SI 7.67 – модели допускают высокую абсолютную ошибку.
- $R^2 < 0.15$ – очень низкое значение, то есть меньше 15% дисперсии SI объясняется моделью.
- RandomForest с настройкой показал наилучшее качество (MAE, RMSE, R^2).
- Ни одна модель не предсказывает SI с высокой точностью.

Это связано с тем, что $SI = CC50 / IC50$ – агрегированная метрика, зависящая от двух источников ошибки.

Рекомендации:

- Не использовать SI как основную цель для регрессии.
- Построить отдельные модели для IC50 и CC50.
- Рассчитать SI как отношение $CC50_pred / IC50_pred$.

5. В ходе сознания модели для классификации превышает ли значение IC50 медианное значение выборки выполнено:

- Загрузка и подготовка данных
- Расчет медианного значения целевой переменной
- Разделение данных на целевую переменную и признаки
- Анализ распределения классов
- Выборки разделены на тестовую и тренировочную
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

- Classification Report: RandomForest (Best)

	precision	recall	f1-score	support
0	0.679000	0.716000	0.697000	74.000000
1	0.696000	0.658000	0.676000	73.000000
accuracy	0.687000	0.687000	0.687000	0.687000
macro avg	0.688000	0.687000	0.687000	147.000000
weighted avg	0.688000	0.687000	0.687000	147.000000

ROC-AUC Score: 0.7428

XGBoost (Best)

[[55 19]
[24 49]]

Classification Report: XGBoost (Best)

	precision	recall	f1-score	support
0	0.696000	0.743000	0.719000	74.000000
1	0.721000	0.671000	0.695000	73.000000
accuracy	0.707000	0.707000	0.707000	0.707000
macro avg	0.708000	0.707000	0.707000	147.000000
weighted avg	0.708000	0.707000	0.707000	147.000000

ROC-AUC Score: 0.7535

CatBoost (Best)

[[52 22]
[24 49]]

Classification Report: CatBoost (Best)

	precision	recall	f1-score	support
0	0.684000	0.703000	0.693000	74.000000
1	0.690000	0.671000	0.681000	73.000000
accuracy	0.687000	0.687000	0.687000	0.687000
macro avg	0.687000	0.687000	0.687000	147.000000
weighted avg	0.687000	0.687000	0.687000	147.000000

ROC-AUC Score: 0.7591

Вывод:

- XGBoost показал наилучшие значения по accuracy и f1-score, что указывает на более сбалансированное качество классификации по сравнению с другими моделями.
- CatBoost продемонстрировал наивысший ROC-AUC 0.759, что говорит о лучшем умении модели различать два класса по вероятностным предсказаниям.
- RandomForest уступает обоим другим моделям по всем метрикам.

Рекомендации:

- XGBoost можно выбрать как основную модель для данной задачи, так как она даёт оптимальный баланс между метриками.
- Если важна максимальная чувствительность к различию классов, можно дополнительно рассмотреть CatBoost, учитывая его высокий ROC-AUC.

6. В ходе сознания модели для классификации превышает ли значение CC50 медианное значение выборки выполнено:

- Загрузка и подготовка данных
- Расчет медианного значения целевой переменной
- Разделение данных на целевую переменную и признаки
- Анализ распределения классов
- Выборки разделены на тестовую и тренировочную
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

RandomForest (Best)

[[46 28]
[20 53]]

Classification Report: RandomForest (Best)

	precision	recall	f1-score	support
0	0.697000	0.622000	0.657000	74.000000
1	0.654000	0.726000	0.688000	73.000000
accuracy	0.673000	0.673000	0.673000	0.673000
macro avg	0.676000	0.674000	0.673000	147.000000
weighted avg	0.676000	0.673000	0.673000	147.000000

ROC-AUC Score: 0.7511

XGBoost (Best)

[[46 28]
[19 54]]

Classification Report: XGBoost (Best)

	precision	recall	f1-score	support
0	0.708000	0.622000	0.662000	74.000000
1	0.659000	0.740000	0.697000	73.000000
accuracy	0.680000	0.680000	0.680000	0.680000
macro avg	0.683000	0.681000	0.679000	147.000000
weighted avg	0.683000	0.680000	0.679000	147.000000

ROC-AUC Score: 0.7549

CatBoost (Best)

[[44 30]

[18 55]]

Classification Report: CatBoost (Best)

	precision	recall	f1-score	support
0	0.710000	0.595000	0.647000	74.000000
1	0.647000	0.753000	0.696000	73.000000
accuracy	0.673000	0.673000	0.673000	0.673000
macro avg	0.678000	0.674000	0.672000	147.000000
weighted avg	0.679000	0.673000	0.671000	147.000000

ROC-AUC Score: 0.7567

Вывод:

- XGBoost показал наилучшие значения по accuracy и f1-score, что указывает на более сбалансированное качество классификации по сравнению с другими моделями.
- CatBoost продемонстрировал наивысший ROC-AUC 0.7567, что говорит о лучшем умении модели различать два класса по вероятностным предсказаниям.
- RandomForest после настройки стал ближе к остальным, но не даёт преимущества по ключевым метрикам.

Рекомендации:

- XGBoost можно выбрать как основную модель для данной задачи, так как она даёт оптимальный баланс между метриками.
- Если важна максимальная чувствительность к различию классов, можно дополнительно рассмотреть CatBoost, учитывая его высокий ROC-AUC.

**7. В ходе сознания модели для классификации превышает ли значение SI
медианное значение выборки выполнено:**

- Загрузка и подготовка данных
- Расчет медианного значения целевой переменной
- Разделение данных на целевую переменную и признаки
- Анализ распределения классов
- Выборки разделены на тестовую и тренировочную
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

RandomForest (Best)

[[49 25]
[30 43]]

Classification Report: RandomForest (Best)

	precision	recall	f1-score	support
0	0.620000	0.662000	0.641000	74.000000
1	0.632000	0.589000	0.610000	73.000000
accuracy	0.626000	0.626000	0.626000	0.626000
macro avg	0.626000	0.626000	0.625000	147.000000
weighted avg	0.626000	0.626000	0.625000	147.000000

ROC-AUC Score: 0.6457

XGBoost (Best)

[[47 27]
[29 44]]

Classification Report: XGBoost (Best)

	precision	recall	f1-score	support
0	0.618000	0.635000	0.627000	74.000000
1	0.620000	0.603000	0.611000	73.000000
accuracy	0.619000	0.619000	0.619000	0.619000

Classification Report: XGBoost (Best)

	precision	recall	f1-score	support
macro avg	0.619000	0.619000	0.619000	147.000000
weighted avg	0.619000	0.619000	0.619000	147.000000

ROC-AUC Score: 0.6542

CatBoost (Best)

[[46 28]
[32 41]]

Classification Report: CatBoost (Best)

	precision	recall	f1-score	support
0	0.590000	0.622000	0.605000	74.000000
1	0.594000	0.562000	0.577000	73.000000
accuracy	0.592000	0.592000	0.592000	0.592000
macro avg	0.592000	0.592000	0.591000	147.000000
weighted avg	0.592000	0.592000	0.591000	147.000000

ROC-AUC Score: 0.6437

Вывод:

- RandomForest лидер по метрикам точности и F1-score, что делает его наиболее сбалансированным вариантом
- XGBoost немного уступает в точности, но показывает наивысшее значение ROC-AUC 0.6542.
- CatBoost, несмотря на настройку параметров, показывает наихудшие результаты среди трёх моделей.

Рекомендации:

- Рекомендуется использовать RandomForest и XGBoost

8. В ходе сознания модели для классификации превышает ли значение SI значение 8 выполнено:

- Загрузка и подготовка данных
- Разделение данных на 2 класса, SI > 8 и все остальное
- Разделение данных на целевую переменную и признаки
- Анализ распределения классов
- Выборки разделены на тестовую и тренировочную

- Устранение дисбаланса классов с помощью SMOTE
- Выбраны алгоритмы для обучения моделей
- Обучены модели с применением базовых настроек
- Подобраны параметры с помощью GridSearchCV
- Обучены модели с лучшими параметрами
- Произведено сравнение выбор результатов с лучшими метриками
- Сделаны выводы и рекомендации

RandomForest (Best)

[[85 20]
[31 11]]

Classification Report: RandomForest (Best)

	precision	recall	f1-score	support
0	0.733000	0.810000	0.769000	105.000000
1	0.355000	0.262000	0.301000	42.000000
accuracy	0.653000	0.653000	0.653000	0.653000
macro avg	0.544000	0.536000	0.535000	147.000000
weighted avg	0.625000	0.653000	0.636000	147.000000

ROC-AUC Score: 0.5913

XGBoost (Best)

[[89 16]
[29 13]]

Classification Report: XGBoost (Best)

	precision	recall	f1-score	support
0	0.754000	0.848000	0.798000	105.000000
1	0.448000	0.310000	0.366000	42.000000
accuracy	0.694000	0.694000	0.694000	0.694000
macro avg	0.601000	0.579000	0.582000	147.000000
weighted avg	0.667000	0.694000	0.675000	147.000000

ROC-AUC Score: 0.5734

CatBoost (Best)

[[86 19]
[28 14]]

Classification Report: CatBoost (Best)

	precision	recall	f1-score	support
0	0.754000	0.819000	0.785000	105.000000
1	0.424000	0.333000	0.373000	42.000000
accuracy	0.680000	0.680000	0.680000	0.680000
macro avg	0.589000	0.576000	0.579000	147.000000
weighted avg	0.660000	0.680000	0.668000	147.000000

ROC-AUC Score: 0.6121

Вывод:

- CatBoost с гиперпараметрами показал наивысший ROC-AUC 0.6121 – лучшая способность различать классы, лучший recall и F1-score для положительного класса (1).
- XGBoost даёт лучшую общую точность, но плохо выявляет положительный класс (низкий recall и F1), что критично, если важны SI > 8.
- RandomForest не справляется, accuracy, F1 и ROC-AUC – наихудшие среди всех.

Рекомендации:

- Выбирать CatBoost как финальную модель.
- Если задача ориентирована на обнаружение положительного класса (SI > 8), ориентироваться на recall и ROC-AUC, а не только на accuracy.

9. Общий вывод, анализ, рекомендации.

Полученные модели обладают слабой предсказательной силой и на текущем этапе они не подходят для надёжного практического использования без доработки.

Отметим, что в ходе изучения целевых переменных было установлено:

IC50 (µM или mM) — "Полумаксимальная ингибирующая концентрация"

Назначение:

Показывает концентрацию вещества, при которой подавляется 50% активности вируса/мишени. Это один из главных показателей эффективности препарата.

Практический смысл:

Чем ниже IC50, тем сильнее соединение подавляет цель.

Хорошие кандидаты обычно имеют низкие значения IC50, менее 0.01 очень высокая активность, более 100 почти неактивное вещество

Если IC50 даже $> 10 \text{ mM}$, это уже часто достаточно, чтобы отбросить соединение.

CC50 (μM или mM) — "Полу максимальная цитотоксическая концентрация"

Назначение:

Показывает концентрацию, при которой 50% здоровых клеток погибают. Это метрика токсичности соединения.

Практический смысл:

Чем выше CC50, тем менее токсично вещество.

Желательно, чтобы CC50 было намного выше IC50.

менее 1 высокая токсичность

более 100 нетоксично

CC50 $> 1000 \text{ mM}$ в реальных биотестах практически не встречаются ввиду ограничений растворимости, стоимости реагентов, физиологической неприменимости.

SI (Selectivity Index) — "Индекс избирательности"

Формула: $SI = CC50/IC50$

Назначение:

Характеризует избирательность действия — насколько хорошо соединение подавляет вирус по сравнению с повреждением здоровых клеток.

Практический смысл:

Чем выше SI, тем безопаснее и предпочтительнее соединение.

SI > 10 очень избирательное, считается очень хорошим показателем.

SI < 1 очень опасно или неэффективно

Идеальный кандидат: низкий IC50, высокий CC50, высокий SI

В нашем датасете из 1000 строк, соединений, которые могут считаться лекарствами оказалось всего 485.

Таким образом, для улучшения качества моделей имеет смысл сначала грубо делить данные на лекарства/не лекарства, согласно описанным выше критериям. Затем обучать модели только на данных, которые могут быть лекарствами. Необходимо глубоко изучить биологический смысл признаков с целью поиска закономерностей и сокращения признакового пространства. Также необходимо существенно увеличить выборку соединений.